

성균 요인 모형

김성민

서울대학교
통계학과, 베이지통계 연구실

2024. 12. 09

목차

- 1 공분산 모형
- 2 사후수렴속도
- 3 요인 모형
- 4 성긴 요인 모형

목차

- 1 공분산 모형
- 2 사후수렴속도
- 3 요인 모형
- 4 성긴 요인 모형

- 다변량 통계에서 공분산 추정은 변수들간의 상관성을 이해하는데 중요하다.
- 표본 공분산

$$S = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})^T$$

은 대표적인 공분산 추정량이다.

- Johnstone [2001] 와 Johnstone and Lu [2009] 는 다음과 같은 고차원 가정하에서 표본 공분산의 가장 큰 고유값과 고유벡터가 불일치성을 가짐을 보였다.

$$\frac{p}{n} \rightarrow c > 0.$$

- 수축 추정량
 - Stein [1975], Haff [1980], Ledoit and Wolf [2004] 와 Bodnar et al. [2014] 는
다.
 - Karoui [2008], Ledoit and Wolf [2012] and Lam [2016] suggested orthogonal
invariants shrinkage estimator based on Random matrix theory.
- 수축 통계량은 다음과 같은 조건하에서 얻어진다.
 - 고유값이 $n \rightarrow \infty$ 임에도 발산하지 않는다.
- 고유값이 발산하는 고차원 공분산을 추정하기 위해서 다음과 같은 추가적인
가정이 필요하다.

- 성긴 공분산 (or 정밀도 행렬)
 - Frequentist : Bickel and Levina [2008a] Cai and Zhou [2012] Cai et al. [2016]
 - Bayesian : Banerjee and Ghosal [2015] Lee et al. [2022] Lee and Lee [2023]
- 밴디드 공분산 (or 정밀도 행렬)
 - Frequentist : Bickel and Levina [2008b] Cai et al. [2010] Bien et al. [2016]
 - Bayesian : Banerjee and Ghosal [2014] Lee et al. [2023]
- 성김 혹은 밴디드 가정은 공분산에 대한 사전 지식이 필요하다.

- 스파이크 공분산은 Johnstone [2001] 에 의해 처음으로 제안되었다.
- 다음과 같은 고유분해를 고려하자.

$$\Sigma = \Gamma \Lambda \Gamma^T, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$$

- 스파이크 공분산 Σ 는 k 개의 큰 고유값과 비교적 작은 나머지 고유값으로 이루어져 있다.

$$\lambda_1 > \dots > \lambda_k \gg \lambda_{k+1} > \dots > \lambda_p.$$

- 고차원 가정하에서, 역위샤프 사전분포를 사용하면 고유값 추정량이 퍼지는 경향성을 가진다.
- Berger et al. [2020] 는 다음과 같은 수축역위샤프(Shrinkage Inverse Wishart) 사전분포를 제안하였다.

$$\pi(\Sigma|a, H) \propto \frac{1}{\left| \prod_{i < j} (\lambda_i - \lambda_j) \right|} |\Sigma|^{-a} \text{etr}\left(-\frac{1}{2}\Sigma^{-1}H\right),$$

여기서 $\lambda_1, \dots, \lambda_p$ 는 Σ 의 고유값이다.

- $\left| \prod_{i < j} (\lambda_i - \lambda_j) \right|$ 가 고유값이 퍼지는 현상을 억제한다.
- 모의실험에서 SIW 가 좋은 성능을 보임을 확인하였지만, 이론적인 근거가 제시되지는 않았다.

$$X_i \stackrel{iid}{\sim} N(0, \Sigma), \quad \forall i = 1, \dots, n$$

$$\pi(\Sigma) \propto \frac{\prod_{i=1}^p \lambda_i^{-a_i}}{\left| \prod_{i < j} (\lambda_i - \lambda_j) \right|} \text{etr}\left(-\frac{1}{2} \Sigma^{-1} H\right)$$

- 다음과 같은 Σ 의 고유분해를 고려하자.:

$$\Sigma = \Gamma \Lambda \Gamma^T$$

여기서 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$ 이고 Γ 는 $p \times p$ 고유벡터 행렬이다.

- Σ 에서 (Λ, Γ) 로 변환의 자코비안은 다음과 같다.

$$\left| \frac{\partial \Sigma}{\partial(\Gamma, \Lambda)} \right| = \left| \prod_{i < j} (\lambda_i - \lambda_j) \right|.$$

고유구조의 사후수렴 속도를 얻기 위해서 다음과 같은 가정들을 고려하자.

- ① $n/p \rightarrow 0$.
- ② 상수 $c_0, C_0 > 0$ 가 존재하여 참 공분산의 고유값이 다음을 만족한다.

$$\lambda_{0,1} > \cdots > \lambda_{0,k} > C_0 > \lambda_{0,k+1} > \cdots > \lambda_{0,p} > c_0.$$

- ③ k 개의 큰 고유값이 상수 $\delta_0 > 0$ 에 의해서 잘 구분된다.:

$$\frac{\lambda_{0,j} - \lambda_{0,j+1}}{\lambda_{0,j}} \geq \delta_0, \quad \forall j = 1, \dots, k.$$

- ④ k 개의 큰 고유값에 대해서, $d_j = \frac{p}{n\lambda_{0,j}}$ 가 유계이다.

목차

- 1 공분산 모형
- 2 사후수렴속도**
- 3 요인 모형
- 4 성긴 요인 모형

Theorem

Assume the assumptions on slide 10 ($A1 \sim A4$). If a_1, \dots, a_k are constant, $a_{k+1}, \dots, a_n \approx n$, $a_{n+1}, \dots, a_p \succ p$ and $H = hI_p$ with $h \prec n$, then the posterior convergence rates of eigenvalues satisfy

$$\mathbb{E} \left[\frac{\lambda_i - \lambda_{0,i}}{\lambda_{0,i}} | \mathbb{X} \right] = O\left(\frac{p}{n\lambda_{0,i}}\right) + O(n^{-\frac{1}{2}+\delta}),$$

for $i = 1, \dots, k$ and any small $\delta > 0$.

- This prior achieves the same convergence rate as the Inverse Wishart prior.

Theorem

If $2a_i - 4 = \frac{n\hat{\lambda}_n}{\hat{\lambda}_i - \hat{\lambda}_n}$, $i = 1, \dots, k$ where $\hat{\lambda}_i$ is i th eigenvalue of sample covariance $S = \frac{1}{n}X^T X$, then the posterior convergence rates of eigenvalues satisfy

$$\mathbb{E}\left[\frac{\lambda_i - \lambda_{0,i}}{\lambda_{0,i}} \mid \mathbb{X}\right] = O\left(\frac{1}{\lambda_{0,i}} \sqrt{\frac{p}{n}}\right) + O(n^{-\frac{1}{2}+\delta}),$$

for $i = 1, \dots, k$ and any small $\delta > 0$.

- If the condition $\lambda_{0,i} \lesssim \frac{p}{\sqrt{n}}$ holds, then the convergence rate is faster than the prior described in Theorem 1.
- The rate is equal to the shrinkage eigenvalues proposed by Wang and Fan [2017].

$$\hat{\lambda}_j^S = \hat{\lambda}_j - \frac{p}{np - nk - pk} \left(\text{tr}(S) - \sum_{i=1}^k \hat{\lambda}_i \right)$$

- ξ_i : Eigenvector corresponding to λ_i , the i th eigenvalue of the Σ .
- $\xi_{0,i}$: Eigenvector corresponding to $\lambda_{0,i}$, the i th eigenvalue of the true covariance.

Theorem

Under assumption on Theorem 2, the posterior convergence rates of eigenvectors satisfy

$$\mathbb{E}\left[1 - |\xi_{0,i}^T \xi_i|^2 \mid \mathbb{X}\right] = O\left(\frac{p}{n\lambda_{0,i}}\right),$$

for $i = 1, \dots, k$.

목차

- 1 공분산 모형
- 2 사후수렴속도
- 3 요인 모형**
- 4 성긴 요인 모형

- 다음과 같은 모형을 고려하자.

$$Y_i = B\eta_i + \epsilon_i, \quad \epsilon_i \sim N(0, \Sigma_u), \quad i = 1, \dots, n$$

- $\eta_i : N(0, I_K)$ 를 따르는 잠재 요인(latent factor).
- $B \in \mathbb{R}^{p \times K}$: 잠재요인 η_i 와 관측 변수 Y_i 를 연관시키는 로딩 행렬.
- ϵ_i : 특이 오차
- Σ_e : 특이 공분산

- 다음과 같은 모형을 고려하자.

$$Y_i \sim N(0, BB^T + \Sigma_u)$$

$$BB^T + \Sigma_u = \Gamma \Lambda \Gamma^T + \Sigma_u$$

$$(\Gamma, \Lambda) \sim \prod_{i=1}^p \lambda_i^{-a_i} \text{etr}\left(-\frac{1}{2} \Gamma \Lambda^{-1} \Gamma^T H\right)$$

$$\Sigma_u \sim \pi(\Sigma_u)$$

- $\Gamma \in \mathbb{R}^{p \times k}$: i 번째 열이 BB^T 의 i 번째 고유벡터
- $\Lambda \in \mathbb{R}^{k \times k}$: 대각성분이 BB^T 의 k 개의 고유값인 대각행렬
- Σ_u : 특이 행렬

$$\begin{aligned}
 & \pi(\Gamma, \Lambda, \Sigma_u | Y) \\
 & \propto P(Y | \Gamma, \Lambda, \Sigma_u) \pi(\Gamma, \Lambda) \pi(\Sigma_u) \\
 & \propto |\Gamma \Lambda \Gamma^T + \Sigma_u|^{-\frac{n}{2}} \cdot \prod_{i=1}^k \lambda_i^{-a_i} \cdot \text{etr} \left(-\frac{n}{2} (\Gamma \Lambda \Gamma^T + \Sigma_u)^{-1} S - \frac{1}{2} \Gamma \Lambda^{-1} \Gamma^T H \right) \cdot \pi(\Sigma_u)
 \end{aligned}$$

- $\bar{\Gamma} = Q\Gamma, \quad (S = nQWQ^T)$
- $\Sigma_u^* = Q^T \Sigma_u Q$

$$\begin{aligned}
 & \pi(\bar{\Gamma}, \Lambda, \Sigma_u^* | Y) \\
 & \propto |\bar{\Gamma} \Lambda \bar{\Gamma}^T + \Sigma_u^*|^{-\frac{n}{2}} \cdot \prod_{i=1}^k \lambda_i^{-a_i} \cdot \text{etr} \left(-\frac{n}{2} (\bar{\Gamma} \Lambda \bar{\Gamma}^T + \Sigma_u^*)^{-1} W - \frac{h}{2} \bar{\Gamma} \Lambda^{-1} \bar{\Gamma}^T \right) \cdot \pi(\Sigma_u)
 \end{aligned}$$

- 깁스 추출법을 이용
- ① Sampling Λ : Inverse Wishart 에서 샘플링 후 Rejection Sampling (or MH)

$$q(\Lambda|\cdot) \propto \prod_{i=1}^k \lambda_i^{-n/2-a_i} \text{etr}\left(-\frac{1}{2}\Lambda^{-1}(n\bar{\Gamma}^T W \bar{\Gamma} + h l_k)\right)$$

- ② Sampling $\bar{\Gamma}$: Matrix Bingham distribution 에서 샘플링 후 Rejection Sampling (or MH)

$$q(\bar{\Gamma}|\cdot) \propto \text{etr}\left(-\frac{1}{2}\Lambda^{-1}\bar{\Gamma}^T(nW + h l_p)\bar{\Gamma}\right)$$

- ③ Sampling Σ_u : $\pi(\Sigma_u)$ 에서 샘플링 후 Rejection Sampling (or MH)

Matrix Bingham 분포의 샘플링

$$P(X) \propto \text{etr}(BX^TAX)I(X \in O(p \times k))$$

- $X = \{Nz, X_{[:, -1]}\}, \quad z \in \mathcal{S}_{p-k+1}$
- N : Orthonormal basis for the null space of $X_{[:, -1]}$

$$\begin{aligned}P(z|X_{[:, -1]}) &\propto \exp(b_{1,1}z^T N^T A Nz)I(z \in \mathcal{S}_{p-k+1}) \\ &\propto \exp\left(z^T \tilde{A} z\right)I(z \in \mathcal{S}_{p-k+1})\end{aligned}$$

- 위의 분포는 vector Bingham distribution 이므로 샘플링 가능
- 각 열에 대해서 샘플링 반복

목차

- 1 공분산 모형
- 2 사후수렴속도
- 3 요인 모형
- 4 **성긴 요인 모형**

- 다음과 같은 모형을 고려하자

$$Y_i \sim N(0, BB^T + \sigma^2 I_p)$$

$$BB^T + \sigma^2 I_p = \Gamma \Lambda \Gamma^T + \sigma^2 I_p$$

$$(\Gamma, \Lambda | R) \sim \prod_{i=1}^p \lambda_i^{-a_i} \text{etr}\left(-\frac{1}{2} \Gamma \Lambda^{-1} \Gamma^T H\right) I(\Gamma = \Gamma \otimes R)$$

$$R \sim \prod_{i,j} \text{Ber}(R_{ij}; \theta) I(\text{supp}(R_{.i}) \geq k)$$

$$\sigma^2 \sim \pi(\sigma^2)$$

- $\Gamma \in \mathbb{R}^{p \times k}$: i 번째 열이 BB^T 의 i 번째 고유벡터
- $R \in \mathbb{R}^{p \times k}$: Γ 의 성김에 대한 이진 행렬
- $\Lambda \in \mathbb{R}^{k \times k}$: 대각성분이 BB^T 의 k 개의 고유값인 대각행렬

$$\pi(\Gamma_{.i}, R_{.i} | R_{-i}, \Gamma_{-i}, \cdot) \propto \exp\left(-\frac{1}{2} \Gamma_{.i}^T B \Gamma_{.i}\right) I(\Gamma_{.i} = \Gamma_{.i} \otimes R_{.i}) \\ \times \prod_j \text{Ber}(R_{ji}; \theta) I(\text{supp}(R_{.i}) \geq k)$$

- 따라서, 먼저 $\pi(R_{.i} | R_{-i}, \Gamma_{-i}, \cdot)$ 에서 샘플링

$$\pi(R_{.i} | R_{-i}, \Gamma_{-i}, \cdot) \\ \propto \int_{\mathcal{S}_{p-1}} \exp\left(-\frac{1}{2} \Gamma_{.i}^T B \Gamma_{.i}\right) I(\Gamma_{.i} = \Gamma_{.i} \otimes R_{.i}) d\Gamma_{.i} \cdot \prod_j \text{Ber}(R_{ji}; \theta) I(\text{supp}(R_{.i}) \geq k) \\ = \int_{\mathcal{S}_{|R_{.i}|-1}} \exp\left(-\frac{1}{2} \Gamma_{r_i}^T B_{r_i, r_i} \Gamma_{r_i}\right) d\Gamma_{r_i} \cdot \prod_j \text{Ber}(R_{ji}; \theta) I(\text{supp}(R_{.i}) \geq k)$$

- 이후에 $\pi(\Gamma_{.i} | R, \Gamma_{-i}, \cdot)$ 에서 샘플링

$$\pi(\Gamma_{.i} | R, \Gamma_{-i}, \cdot) \propto \exp\left(-\frac{1}{2} \Gamma_{.i}^T B \Gamma_{.i}\right) I(\Gamma_{.i} = \Gamma_{.i} \otimes R_{.i})$$

Hypergeometric function of matrix argument

$${}_1F_1\left(\frac{1}{2}; \frac{p}{2}; Z\right) = \int_{S_{p-1}} \exp(x^T Z x) dx, \quad Z : \text{diagonal matrix}$$

- Bingham 분포의 상수항이 Hypergeometric function 형태가 된다.
- 샘플링을 위해서는 Hypergeometric function 처리가 필요

$$\pi(\Gamma_{.i}|R, \Gamma_{-i}, \cdot) \propto \exp\left(-\frac{1}{2}\Gamma_{.i}^T B \Gamma_{.i}\right) I(\Gamma_{.i} = \Gamma_{.i} \otimes R_{.i})$$

- 만약에 $\text{supp}(R_{.i}) \geq k$ 가 아니라면 Γ 가 직교행렬이 되도록 하는 $\Gamma_{.i}$ 가 존재하지 않을 수 있다.
- 하지만 해당 가정은 $\Gamma_i = e_i$ 인 경우를 설명하지 못한다.
- $\text{supp}(R_{.i}) < k$ 인 경우에는 $R_{.i}$ 의 가능한 집합이 Γ_{-i} 에 의존한다.
 - $o_i = \{j : R_{ji} = 1\}$
 - $\Gamma_{o_i, -i}$ 의 rank 가 $\min(n(o_i), k)$ 보다 작아야 한다. ($\text{null}(\Gamma_{o_i, -i}) \neq \phi$)

References I

- Sayantan Banerjee and Subhashis Ghosal. 2014. Posterior convergence rates for estimating large precision matrices using graphical models. *Electronic Journal of Statistics* 8 (2014), 2111–2137.
- Sayantan Banerjee and Subhashis Ghosal. 2015. Bayesian structure learning in graphical models. *Journal of Multivariate Analysis* 136 (2015), 147–162.
- James O Berger, Dongchu Sun, and Chengyuan Song. 2020. Bayesian analysis of the covariance matrix of a multivariate normal distribution with a new class of priors. *The Annals of statistics* 48, 4 (2020), 2381–2403.
- Peter J Bickel and Elizaveta Levina. 2008a. Covariance Regularization by Thresholding. *The Annals of Statistics* (2008), 2577–2604.
- Peter J Bickel and Elizaveta Levina. 2008b. Regularized Estimation of Large Covariance Matrices. *The Annals of Statistics* (2008), 199–227.
- Jacob Bien, Florentina Bunea, and Luo Xiao. 2016. Convex banding of the covariance matrix. *J. Amer. Statist. Assoc.* 111, 514 (2016), 834–845.

References II

- Taras Bodnar, Arjun K Gupta, and Nestor Parolya. 2014. On the strong convergence of the optimal linear shrinkage estimator for large dimensional covariance matrix. *Journal of Multivariate Analysis* 132 (2014), 215–228.
- T Tony Cai, Zhao Ren, and Harrison H Zhou. 2016. Estimating structured high-dimensional covariance and precision matrices: Optimal rates and adaptive estimation. *Electronic Journal of Statistics* 10 (2016), 1–59.
- T Tony Cai, Cun-Hui Zhang, and Harrison H Zhou. 2010. OPTIMAL RATES OF CONVERGENCE FOR COVARIANCE MATRIX ESTIMATION. *The Annals of Statistics* 38, 4 (2010), 2118–2144.
- T Tony Cai and Harrison H Zhou. 2012. OPTIMAL RATES OF CONVERGENCE FOR SPARSE COVARIANCE MATRIX ESTIMATION. *The Annals of Statistics* (2012), 2389–2420.
- LR Haff. 1980. Empirical Bayes estimation of the multivariate normal covariance matrix. *The Annals of Statistics* 8, 3 (1980), 586–597.
- Iain M Johnstone. 2001. On the distribution of the largest eigenvalue in principal components analysis. *The Annals of statistics* 29, 2 (2001), 295–327.

References III

- Iain M Johnstone and Arthur Yu Lu. 2009. On consistency and sparsity for principal components analysis in high dimensions. *J. Amer. Statist. Assoc.* 104, 486 (2009), 682–693.
- Noureddine El Karoui. 2008. Spectrum Estimation for Large Dimensional Covariance Matrices Using Random Matrix Theory. *The Annals of Statistics* (2008), 2757–2790.
- Clifford Lam. 2016. Nonparametric eigenvalue-regularized precision or covariance matrix estimator. *Annals of Statistics* 44, 3 (2016), 928–953.
- Olivier Ledoit and Michael Wolf. 2004. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of multivariate analysis* 88, 2 (2004), 365–411.
- Olivier Ledoit and Michael Wolf. 2012. Nonlinear shrinkage estimation of large-dimensional covariance matrices. *The Annals of Statistics* 40, 2 (2012), 1024–1060.

References IV

- Kyoungjae Lee, Seongil Jo, and Jaeyong Lee. 2022. The beta-mixture shrinkage prior for sparse covariances with near-minimax posterior convergence rate. *Journal of Multivariate Analysis* 192 (2022), 105067.
- Kwangmin Lee and Jaeyong Lee. 2023. Post-processed posteriors for sparse covariances. *Journal of Econometrics* 236, 1 (2023), 105475.
- Kwangmin Lee, Kyoungjae Lee, and Jaeyong Lee. 2023. Post-processed posteriors for banded covariances. *Bayesian Analysis* 18, 3 (2023), 1017–1040.
- Charles Stein. 1975. Estimation of a covariance matrix. In *39th Annual Meeting IMS, Atlanta, GA, 1975*.
- Weichen Wang and Jianqing Fan. 2017. Asymptotics of empirical eigenstructure for high dimensional spiked covariance. *Annals of statistics* 45, 3 (2017), 1342.